

programa de pós-graduação em
ENGENHARIA DE DEFESA

Álgebra Linear Computacional

Parte VIII

Maj Hebert **AZEVEDO** Sá, Ph.D.

Existem problemas matemáticos para os quais pequenas variações nos dados de entrada produzem grandes variações nas respostas (i.e., nas saídas).

A **sensibilidade** é a medida de quanto a solução de um problema matemático varia em resposta a pequenas alterações nos dados de entrada.

Um problema é dito **mal condicionado** quando é **muito sensível** a pequenas perturbações nos dados. Contrariamente, problemas **bem condicionados** são **pouco sensíveis**.

Devido a características de aproximações de ponto flutuante, os algoritmos de álgebra linear computacional podem apresentar resultados *inesperados ou de má qualidade* quando comparados com resultados da álgebra linear puramente teórica.

A **estabilidade** de um algoritmo mede sua capacidade de não introduzir ou amplificar erros para além do condicionamento do próprio problema.

Há dois tipos: erro diretamente propagado e erro retro-propagado (*forward* e *backward error*).

Seja um algoritmo que calcula $f(x)$ a partir de um conjunto de entradas x . Por conta de imprecisões, o valor retornado pelo computador que roda o algoritmo é dado por $\hat{f}(x)$.

Erro diretamente propagado: É dado por $|\hat{f}(x) - f(x)|$.

Erro retro-propagado: É dado pelo menor Δx tal que $f(x + \Delta x) = \hat{f}(x)$.

Exemplo [Ford, 10.4]: A série de McLaurin para $f(x) = \frac{1}{1-x}$ é dada por

$$\frac{1}{1-x} = 1 + x + x^2 + \cdots = \sum_{n=0}^{\infty} x^n, \quad |x| < 1.$$

Supondo uma aproximação numérica dada por

$\hat{f}(x) = 1 + x + x^2 + x^3 + x^4 + x^5 + x^6 + x^7$, teremos:

$$f(0.57) = 2.32558139535\dots, \quad \hat{f}(0.57) = 2.2997.$$

O erro diretamente propagado será $|2.32558139535\dots - 2.2997| \approx 0.0259$.

O erro retro-propagado será $|\hat{x} - x|$ tal que $\frac{1}{1-\hat{x}} = 2.2997$. Isto é, $\hat{x} = 0.56516$ e $|\hat{x} - x| = 0.00484$.

Um algoritmo é diretamente estável quando computa boas aproximações, isto é, $|\hat{f}(x) - f(x)|$ é pequeno.

Um algoritmo é retroativamente estável quando, para qualquer x , computa $\hat{f}(x)$ com erro retro-propagado pequeno. Portanto, na prática, esse algoritmo computa uma solução para um problema “vizinho”, $f(x + \Delta x) = \hat{f}(x)$, tal que a solução não é sensível a pequenas variações de x .

Exemplos de algoritmos instáveis:

Cálculo do posto de uma matriz xy^T :

$\hat{A} = (x + \Delta x)(y + \Delta y)^T = xy^T + \Delta$, que em geral tem posto diferente de 1!

Exemplos de algoritmos instáveis:

Seja o cálculo de $f(x) = \sqrt{x^2 + 1} - x$ para x “relativamente grande”. Analiticamente, sabe-se que, para $x = 10^8$, tem-se $f(10^8) \approx 5 \times 10^{-9}$.

Ao calcularmos $f(x)$ com o algoritmo direto em um sistema computacional com truncamento, esse resultado pode reduzir-se a 0.

Podemos mudar o algoritmo de cálculo de $f(x)$ fazendo

$$f(x) = \frac{1}{\sqrt{x^2 + 1} + x}$$

e encontrar um resultado muito próximo do correto evitando a subtração de números muito próximos entre si.

Um problema é mal condicionado quando uma pequena variação em seus dados gera uma grande variação na sua solução.


Exemplo: problema de *Cauchy*:

$$\frac{dx}{dt} = x(t) - t, t > 0, x(0) = 1$$

ou

$$\frac{dx}{dt} = x(t) - t, t > 0, x(0) = 1 + \epsilon$$

Condicionamento de problemas



Condicionamento de problemas

Definição: Número de condicionamento.

Sabemos que um problema dado por $f(x)$ é bem condicionado com relação a x se, $|x - \bar{x}|$ pequeno $\implies |f(x) - f(\bar{x})|$ pequeno.

o Número de Condicionamento de um problema $f(x)$ em x será

$$C_f(x) = \lim_{\epsilon \rightarrow 0^+} \sup_{\|\delta x\| \leq \epsilon} \frac{\frac{\|f(x+\delta x) - f(x)\|}{\|f(x)\|}}{\frac{\|\delta x\|}{\|x\|}}$$

que em geral pode-se aproximar por

$$C_f(x) = |x| \frac{|f'(x)|}{|f(x)|}$$

Exemplo: [Ford], Example 10.7

Seja um sistema linear $Ax = b$, tal que A é uma matriz não singular e $\|\cdot\|$ é uma norma.

O número dado por $\kappa(A) = \|A\| \|A^{-1}\|$ é o número de condicionamento da matriz, e indica o condicionamento do sistema linear.

Quando $\kappa(A)$ é grande (i.e., normalmente maior que 10^4), A é mal condicionada.

Para calcular o número de condicionamento com numpy: `numpy.linalg.cond`
(numpy.org/doc/stable/reference/generated/numpy.linalg.cond.html)